```
==================================================
ЗАПУСК СИМУЛЯЦИИ: N (Кол-во GPU) = 14
1_000_000 логов:
MAX_CHUNK_SIZE: = 1024
MAX_BATCH_SIZE = 42 сколько макс рекв в батч
==================================================

--- БАЗОВАЯ СТАТИСТИКА ---
Всего запросов обработано: 999995
Провалено по SLA: 66047 (6.60%)

--- АНАЛИТИКА TTFT (Time To First Token) ---
Лимит SLA (P): 10 сек
Среднее: 4.8687 сек
Медиана (P50): 0.8192 сек
P90: 4.3967 сек
P99: 105.2423 сек
Максимум: 7311.8531 сек

--- АНАЛИТИКА DECODE (Время на 1 токен генерации) ---
Лимит SLA (D): 1 сек
Среднее: 0.1580 сек
Медиана (P50): 0.1000 сек
P90: 0.3066 сек
P99: 0.9701 сек
Максимум: 17.9932 сек
```

```
--- УТИЛИЗАЦИЯ И ПРОСТОЙ GPU (EMPIRICAL IDLE TIME) ---
GPU 0: Утилизация 94.7% | Работа: 573875.7s | Простой: 31840.5s
GPU 1: Утилизация 93.7% | Работа: 567709.1s | Простой: 38007.1s
GPU 2: Утилизация 92.3% | Работа: 559152.8s | Простой: 46563.4s
GPU 3: Утилизация 90.6% | Работа: 548998.5s | Простой: 56717.7s
GPU 4: Утилизация 89.2% | Работа: 540355.8s | Простой: 65360.4s
GPU 5: Утилизация 87.1% | Работа: 527827.9s | Простой: 77888.3s
GPU 6: Утилизация 84.9% | Работа: 514290.9s | Простой: 91425.3s
GPU 7: Утилизация 82.6% | Работа: 500460.5s | Простой: 105255.7s
GPU 8: Утилизация 80.3% | Работа: 486166.3s | Простой: 119549.8s
GPU 9: Утилизация 77.5% | Работа: 469681.9s | Простой: 136034.3s
GPU 10: Утилизация 76.2% | Работа: 461287.2s | Простой: 144429.0s
GPU 11: Утилизация 73.8% | Работа: 447194.9s | Простой: 158521.3s
GPU 12: Утилизация 72.1% | Работа: 436934.3s | Простой: 168781.8s
GPU 13: Утилизация 70.4% | Работа: 426213.4s | Простой: 179502.8s
Средняя загрузка кластера (Useful Compute): 83.26%
Суммарный простой кластера (Idle Time): 1,419,877.40 сек из общих 8,480,026.72 машино-секунд
```

Вывод:

Требуется минимально 14 ГПУ, где

спеки:

- VRAM = 80GB
- COST_A = 0.5 # на картинку
- COST_B = 0.01 # обработка 1 токена контекста
- COST_C = 0.05 # 1 сгенерированный токен
- в среднем считалось ttft на миллион запросов = 4.8687 сек
- в среднем от ttft до полноценного ответа (decode = stage1 + stage2) = 0.1580 сек Общее время на миллион логов = (4.8687 + 0.1580) * 1кк = 5_026_700 секунд

Когда в нижний предел = 1_425_225 секунд А верхний = 45_607_213 секунд

Эмпирические результаты показали хорошие метрики, в том числе маленькое время простоя, так как в Discrete Event Simulator было по ходу развития имплементировано симуляции вот этих идей:

- Continious Batching
- Chunked Prefill
- KV-cache (легкое подобие) ((иначе расчет был для каждого слоя, а ещё один гиперпараметр это ещё больше усложнений))
- Eviction Policy